헥사포드 험지 보행에서 EUREKA 의 유효성 검증

최용준* · 김민규*· 강성재*
* 홍익대학교 기계시스템디자인공학과

Validation of EUREKA's Effectiveness in Hexapod Rough-Terrain Locomotion

Yong Jun Choi*, Min Gyu Kim* and Seong Jae Kang*
* Mechanical System & Design Engineering, Hongik Univ

(Received June 16, 2025 ; Revised June 25, 2025 ; Accepted June 27, 2025)

Key Words: EUREKA, Reinforcement Learning(강화학습), Hexapod Robot(6 족 로봇), Rough Terrain(험지), Locomotion(보행)

초록: 본 연구는 대규모 언어 모델 기반 보상 설계 자동화 프레임워크인 **EUREKA** 의 헥사포드 험지 보행 제어에 대한 유효성을 검증하였다. 몸체 길이 18.8 cm, 18 자유도를 가진 헥사포드 로봇을 IsaacLab 시뮬레이션 환경에 구현하고, 경사 · 요철이 무작위로 배치된 험지에서 부분 관측 마르코프 결정(POMDP) 과정으로 학습을 수행하였다. EUREKA 는 다섯 회차에 걸쳐 보상 함수를 생성 · 개선하였으며, 최종 회차에서 평균 전진 속도 0.78m/s 와 안정적인 보행을 달성하였다. 성능 분석 결과 회차가 진행될 때 마다 보상 함수가 반복적으로 개선되어 초기 수렴 속도가 단축되고 최대 속도가 증가함을 확인하였다. 이는 복잡한 다족 보행 로봇에서도 LLM 기반 보상 자동화가 효과적으로 작동함을 시사하며, POMDP 환경에서 EUREKA 의 적용 범위를 확장한다. 향후 실제 로봇에 적용 시 시뮬레이션을 현실로 구현하는 방법과 계산 자원 요구를 완화하기 위한 추가적인 연구가 필요하다.

Abstract: This study verifies the effectiveness of **EUREKA**, a large-language-model–based automatic reward-design framework, for controlling hexapod locomotion on rough terrain. An 18-DOF hexapod robot with a body length of 18.8 cm was modeled in the IsaacLab simulation environment and trained under a partially observable Markov decision process (POMDP) on terrains with randomly distributed slopes and obstacles. Across five iterations, EUREKA generated and refined reward functions; in the final iteration the robot achieved an average forward speed of 0.78 m s^{-1} while maintaining stable gait. Performance analysis shows that each successive reward improved initial convergence rates and raised peak speed, demonstrating that LLM-driven reward automation functions effectively even for complex multi-legged robots and broadens EUREKA's applicability to POMDP settings. Future work should address sim-to-real transfer and reduce computational overhead when deploying the framework on physical robots.

1. 서론

1.1 문제 제기

다족 보행 로봇은 바퀴나 무한궤도가 접근하기 어려운 불규칙한 험지에서도 높은 기동성을 발휘할 수 있다. 특히 여섯 개의 다리를 가진 헥사포드 로봇은 보행 중 다수의 다리를 통해 안정성을 확보하여 재난 구조, 행성 탐사 등 예측 불가능한 환경에서의 임무 수행에 높은 적합성을 보인다. 다수의 다리를 조화롭게 제어하여 복잡한 지형 위에서 안정적이고 효율적인 보행을 구현하는 것은 로봇 공학 분야의 핵심적인 도전 과제로 남아있다.

이러한 복잡한 제어 문제를 해결하기 위한 효과적인 방법으로 강화학습이 부상했다. 피드백 루프를 활용한 고전적인 제어 방식은 사람이 모든 경우의 수를 고려하여 피드백 회로를 설계해야 하며, 고려되지 않은 환경에서 작동을 보장할 수 없는 명확한 한계가 존재했다. 강화학습은 신경망이

움직이는 방법을 스스로 학습하도록 유도함으로써 고전적 제어의 단점을 해결했다. 하지만 강화학습을 성공적으로 적용하기 위해서는 학습의 목표와 방향을 정의하는 보상 함수를 매우 정교하게 설계해야 한다. 따라서 해당 분야에 대한 깊은 지식과 공학적 직관을 가진 인간 전문가의 반복적인 시행착오에 크게 의존한다는 한계점이 남았다.

이 한계를 해결하기 위해 2023 년 NVIDIA 연구팀에서 대규모 언어 모델(LLM)을 활용하여 강화학습의 보상 함수 생성을 자동화하는 EUREKA 시스템을 제안했다. EUREKA 는 인간 전문가가 수행하던 지루하고 반복적인 보상 공학 과정을 인공지능이 대체함으로써 복잡한 로봇 제어 과제를 더욱 빠르고 효율적으로 자동화 할 수 있는 새로운 가능성을 열었다. 선행 연구에서 EUREKA 는 사족보행 로봇, 로봇 손 등 다양한 로봇의 제어 지능을 성공적으로 학습시키는 성과를 보였다.

그러나 EUREKA 는 헥사포드 로봇의 보행 문제에 대해서 아직 그 유효성이 검증되지 않았다. 헥사포드의 기구학적, 동역학적 복잡성은 보상 함수 설계의 난이도를 기하급수적으로 높이는 요인이다. 따라서 헥사포드를 강화학습시키는 데 존재하는 한계점이 해결되었다고 보기 위해서는 EUREKA 가 헥사포드의 높은 복잡성을 효과적으로 처리할 수 있는지에 대한 별도의 검증이 반드시 필요하다.

이에 본 연구는 EUREKA 시스템을 헥사포드 로봇, 그 중에서도 소위 거미 로봇이라 불리는 18 의 자유도를 가진 로봇의 험지 보행 제어 문제에 적용하여 그 실효성을 검증하는 것을 목표로 한다. 구체적으로 EUREKA 를 이용하여 헥사포드의 험지 보행을 위한 강화학습을 수행하고, 이 과정에서 대규모 언어 모델이 생성하는 보상 함수에 따른 학습 과정의 변화를 심층적으로 분석한다. 이를 통해 EUREKA 프레임워크의 적용 범위를 더 높은 복잡성을 지닌 로봇 시스템으로 확장하여 향후 지능형 다족 로봇의 자율 보행 연구에 기여하고자 한다.

1.2 과제

본 연구의 구체적인 목표는 앞서 제기된 학술적 필요성에 따라 EUREKA 시스템을 헥사포드 로봇에 적용하고 그 유효성을 정량적으로 검증하는 것이다. 목표를 달성하기 위해 다음과 같은 핵심 과제들을 수행한다.

첫째, 강화학습 환경에 적합한 단순화된 헥사포드 모델을 제작한다.

둘째, 강화학습을 위한 파이썬 코드를 작성한다.

셋째, 험지 보행 성능을 효과적으로 평가할 수 있도록 경사로 및 불규칙한 요철을 포함하는 가상 지형을 설계한다.

넷째, EUREKA 가 보상 함수를 생성하는 데 활용할 로봇의 상태 변수와 목표에 대한 명확한 지침을 정의한다.

상기 과정을 통해 학습 환경을 설정하고, NVIDIA 에서 제공하는 IsaacLab 라이브러리와 EUREKA 를 이용하여 강화학습을 수행한다. 학습된 신경망의 보행 성능은 험지 환경에서의 빠른 전진 이동 속도를 기준으로 삼아 분석하고자 한다. 로봇 동체의 안정성 역시 중요한 성능 지표이지만, 경사로와 불규칙한 노면으로 구성된 험지 환경에서는 안정성을 일관된 기준으로 정량화하기 어렵다는 한계가 존재한다. 따라서 본 연구에서는 험지 주파 능력의 직접적인 척도인 이동 속도에만 초점을 맞추어 EUREKA 의 성능을 우선적으로 평가한다.

2. 문헌 조사

2.1 헥사포드 보행의 최신 연구 동향

헥사포드 로봇은 여섯 개의 다리를 통해 높은 안정성을 가져 복잡한 지형과 예측 불가능한

환경에서의 운용에 강점을 지닌다. 이러한 특성 덕분에 탐사, 감시, 구조 등 다양한 분야에서의 활용 가능성이 높게 평가된다. 그러나 헥사포드가 강점을 지니는 험지에서는 고전적인 피드백 루프 방식의 제어를 적용하는 데 문제가 생긴다. 사람이 직접 반응을 설계하는 피드백 루프 제어는 험지의 불규칙성에 제대로 적응할 수 없다.

최근 헥사포드 로봇의 보행 제어 연구는 이러한 피드백 루프 제어 방식의 한계를 극복하기 위해 강화 학습 기반의 접근 방식에 집중되고 있다. 강화 학습은 보상 함수하고 불리는 평가 기준을 통해 보상을 최대화시키는 방향으로 신경망을 강화시켜 로봇이 스스로 최적의 보행 전략을 학습하도록 유도한다. 적절한 보상 함수와 다양한 험지를 통해 학습할 경우 불규칙한 환경에 범용적으로 적용할 수 있는 신경망이 형성된다.

최근 연구 동향은 이러한 강화 학습을 다양한 방식으로 활용하여 헥사포드 로봇의 보행을 구현하려는 시도가 활발히 진행되고 있다. 일련의 연구에서는 계층적 강화 학습 프레임워크를 제안하여 헥사포드 로봇의 보행 제어 문제를 해결하고, 실제 로봇에 적용하여 평탄한 지면에서의 안정적인 보행 및 낮은 운송 비용을 달성하는 사례들이 보고된다. 또 다른 연구는 중추 패턴 생성기(CPG)와 강화 학습을 결합하여 지형 적응형 보행 제어 방법을 개발하여, 시뮬레이션 환경에서 불균일한 지형에 대한 높은 적응성을 보여준다. 이러한 연구들은 다족 로봇 시스템의 동적 균형 및 환경 적응 제어를 위해 강화학습을 이용하는 것이 효과적인 방법임을 입증하고 있다.

그러나 강화 학습 기반의 헥사포드 보행 제어 연구에는 지속적으로 보상 함수의 설계와 최적화가 핵심적인 난제라고 언급된다. 보상 함수의 각 항에 대한 작은 가중치의 변화가 로봇의 최종 보행 성능에 지대한 영향을 미치기 때문에, 이 가중치 튜닝 과정이 난해하며 연구자의 경험과 시행착오에 크게 의존한다. 특히 18 이라는 높은 자유도를 가진 헥사포드 로봇은 다른 로봇에 비해 방대한 탐색 공간을 형성하여 보상 함수 최적화를 더욱 어렵게 만든다. 이로 인해 원하는 조건을 모두 만족시키는 보상 함수를 설계하는 것이 어렵다는 점이 여러 연구에서 공통적으로 언급된다.

2.2 EUREKA

앞서 언급한 바와 같이 기존 강화 학습 분야에서는 로봇이 복잡한 조작 작업을 학습하는 데 필요한 보상 함수를 수동으로 설계하는 것이 매우 어렵고 시간이 많이 소요되는 과제였다. 수많은 강화 학습 연구자들은 보상 설계가 시행착오를 통해 이루어지며 최적의 결과를 얻기 어렵다고 보고하였다. NVIDIA 연구팀은 이를 해결하기 위해 GPT-4 와 같은 대규모 언어 모델(LLM)을 활용하여 인간 수준의 보상 함수를 자동으로 생성하고 최적화할 수 있는 알고리즘인 EUREKA 를 고안하였다. EUREKA 는 기존 보상함수를 입력하지 않아도 보상 함수를 새롭게 생성하고 인간의 추가적인 개입 없이 스스로 보상 함수를 평가, 개선할 수 있도록 설계되었다.

EUREKA 는 다음과 같은 구조로 작동한다. 우선 LLM 에 역할, 목적, 관측값, 코드 작성 예시, 코드 작성 시 유의사항 등을 포함하는 프롬프트를 입력하여 보상 함수 코드를 생성하도록 한다. 이 코드를 보상이 없는 학습 코드에 삽입한 후 완성된 코드를 통해 강화학습을 시행한다. 이 때 EUREKA 는 여러 보상 후보를 독립적으로 샘플링 한 후 각 샘플에 대한 학습을 시뮬레이션한다. 이후 기준에 따라 여러 샘플 중 가장 잘 작성된 보상함수를 선정한다. 해당 보상함수로 진행된 학습 통계와 보상 함수를 피드백하는 데 필요한 지침을 앞서 제공된 프롬프트에 더해 LLM 에 다시 제공한다. LLM 은 다시 여러 개의 개선된 보상함수를 샘플링 하고 다음 학습 및 평가를 실행하며, 정해진 횟수만큼 이런 루프를 반복한다. LLM 이 여러 개의 샘플을 생성할 때부터 다음번 개선된 코드를 생성까지의 일련의 과정을 하나의 회차(iteration)로 묶어 부른다. 이 알고리즘의 코드 개선 방식은 진화 알고리즘의 변이와 비슷한 방식으로 작동하지만, 변이가 무작위로 일어나지 않고 이전 학습의 통계를 기반으로 LLM 에 의해 제어된다는 특징이 있다.

EUREKA 는 10 가지 로봇을 이용한 29 가지 강화학습 환경에서 인간 수준의 보상 설계 능력을 입증하였다. 구체적으로, 사전 정의된 보상 템플릿 없이도 83%의 작업에서 인간 전문가가 설계한 보상 함수보다 뛰어난 성능을 보였으며, 평균적으로 52%의 정규화된 성능 개선을 이루었다. 특히 이전에는 수동 보상 설계로 해결하기 어려웠던 모의 새도우 핸드의 펜 돌리기와 같은 복잡한 조작 작업을

성공적으로 수행하였다. 또한 EUREKA 는 인간의 피드백을 분석, 평가하여 보상 생성에 이용하는 새로운 비구배(gradient-free) 학습 방식을 제시하여, 기존 인간이 작성한 보상 함수를 개선하거나 인간과 공동으로 보상을 설계할 수 있는 능력도 보여주었다. 이 연구는 대규모 언어 모델과 진화 알고리즘의 결합이 보상 설계라는 난해한 문제에 대한 새로운 해결책이 될 수 있음을 입증하였다.

3. 실험 과정

3.1 공학적/수학적 모델링

3.1.1 모델링

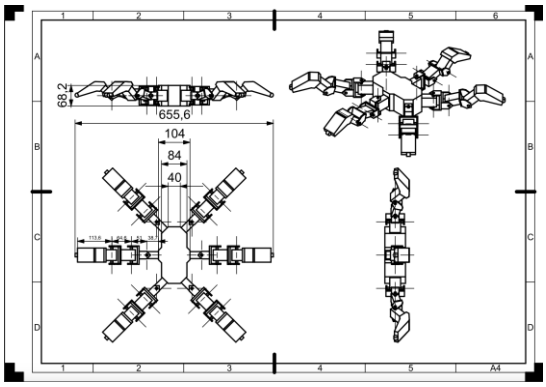

Fig. 1 Blueprint of simplified hexapod model.

헥사포드 모델링은 오픈소스 DIY 모델(https://www.thingiverse.com/thing:3463845#google_vignette)을 선정하였다 선정한 모델링을 시뮬레이션 환경에 맞게끔 곡선은 배재하고 나사같은 미세부품들을 제거하는 방식으로 단순화 시켰으며, PLA 재료 사용 기준 채움 밀도 30%로 출력 시의 무게를 측정하였다. 총 무게에서 브림과 사용자 정의 부분을 제외하여 부품의 실제 무게를 계산하였다.

3.1.2 모터

선정된 모터는 MG996R 이며, 주요 사양은 다음과 같다:

- 무게: 55g
- 토크: 11kgfcm (1.0791Nm)
- 작동 속도: 0.14 s/60° (7.47 rad/s)

HEXAPOD_SIMPLE_ACTUATOR_CFG 라는 이름의 DCMotorCfg 객체를 생성하여 로봇 액추에이터(모터)의 제어 설정을 정의하였다. 각 파라미터의 상세 설명은 다음과 같다:

- joint_names_expr=[".*hip", ".*knee", ".*ankle"]: "hip", "knee", "ankle"을 이름에 포함하는 모든 관절에 이 설정이 적용된다.
- saturation_effort=1.0: 모터에 가해질 수 있는 최대 입력값의 정규화 범위를 정의한다.
- effort_limit=0.5: 제어 입력의 정규화된 최대값(±1)이 실제 물리적 토크 한계로 변환된다.
- velocity_limit=7.47: 각 관절이 낼 수 있는 최대 속도(rad/s)를 설정한다.
- stiffness={".*": 10.0}: 관절의 위치 제어를 위한 비례 이득(k_p)을 설정한다.
- damping={".*": 0.3}: 관절의 속도에 대한 저항 계수(k_d)를 설정한다.

DCMotorCfg 함수의 stiffness 와 damping 계산식은 다음과 같다:
Torque=stiffness×(TargetPosition−ObsPosition)+damping×(TagetVelocity−ObsVelocity)

3.1.3 센서 및 보상 구성요소

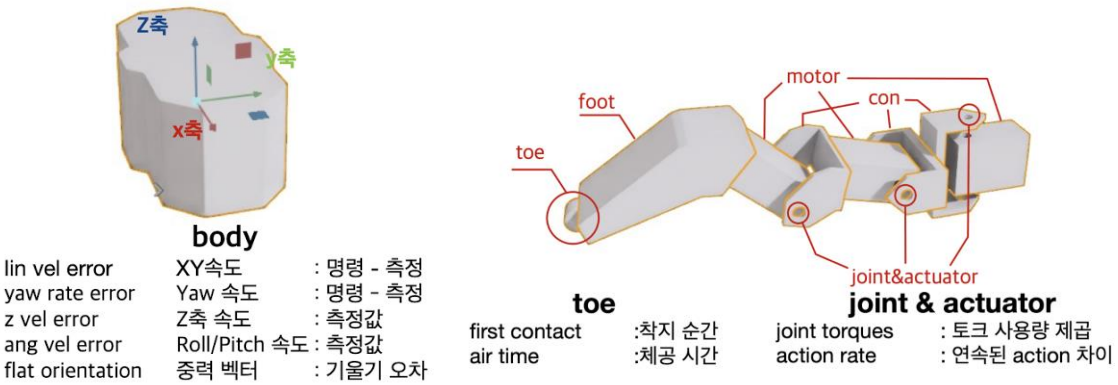

Fig. 2 Sensors and their observations

헥사포드의 중앙 부분을 body 로 지정하고, body 를 기준으로 각 값을 읽어와 보상 구성요소에 사용하였다. 각 다리의 끝 부분은 toe 로 명명하고 접촉 센서를 부착하여 착지 순간을 인식하고 체공 시간을 계산하였다. 각 관절의 revolute joint(위 이미지의 joint&actuator)에서 현재 토크 값과 이전 토크 값을 읽어온다.

3.1.4 코드 세부사항

hexapod.py: revolute joint 에 모터를 부착하고 물리값을 설정하였다. 또한 모델 경로 지정, 중력 등 물리 속성 부여, 초기 위치 및 각 조인트 각도 설정 등 학습에 사용되는 에이전트인 헥사포드를 설정하였다.

hexapod_env_cfg.py: 지형(terrain)을 불러오고 그에 대한 파라미터를 설정하였다. 과적합 방지를 위해 지형과 모델의 물리값에 약간의 랜덤 값을 부여하였으며, 다중 환경 파라미터와 시뮬레이션 코드도 작성하는 등 학습에 필요한 환경과 모델의 파라미터를 설정하였다.

hexapod_env.py: 헥사포드 학습에 사용할 목표 속도를 랜덤으로 부여하고, 보상을 기록하며 로봇을 생성하고 시뮬레이션 환경을 생성한다. 에이전트의 종료 조건과 환경 리셋 등 실질적으로 학습에 필요한 환경들을 생성하고 각 반복(iteration)에서의 학습을 담당하는 코드를 작성했다.

3.2 과정 및 문제 해결

강화 학습을 통해 헥사포드 로봇의 보행 학습을 하는 과정에서 EUREKA 시스템을 IsaacLab 환경에 맞게 수정하고, task 설계와 학습 조건을 지속적으로 개선하였다. 각 과정에서 발생한 문제와 그 해결 방안을 문제점이 발생한 시간 순서대로 다음과 같이 기술한다.

기존 EUREKA 는 Ubuntu / IsaacGym 환경에 맞추어져 있어 우리가 사용할 환경인 Window / IsaacLab 으로 변환하기 위해서 구조 및 환경 경로를 수정하고, torch.jit.script 와 같이 IsaacLab 과 충돌하는 삽입 코드를 제거하였다.

Task Description 을 설정하는 부분에서도 여러 시행착오를 겪었다. 우리는 안전성을 평가할 때 flat_orientation 을 기준으로 사용하는데, 험지에 경사로가 있는 경우 이러한 평가 기준에서 안전성 저하는 불가피하다. Description 에 stably 를 넣는 경우, EUREKA 가 안정성을 과대 평가하는 방향으로 학습을 진행시켜 의도치 않은 학습 결과를 내놓게 되었다. 또한 목표의 최대화를 위해 다른 reward 를 사용해도 된다는 말을 명시를 하지 않으면 목표에 직접적 연관이 있는 obs 값만 사용하는 경향이 생겼다. 이러한 문제점들을 고려하여 최종 결정된 Task Description 은 "Make the hexapod run forward. Maximize the forward velocity. You can use other rewards to maximize it"이다.

다음은 죽음 조건에 관한 내용이다. 땅에 닿더라도 일어설 수 있는 헥사포드 로봇의 특성을 고려하였을 때, 기존의 넘어짐 혹은 충돌에 관한 에피소드 종료 조건은 학습을 방해하는 요소로 작용하였다. 따라서 허용 Force 값을 대폭 완화하여 로봇이 충돌하더라도 회복 동작을 학습할 수 있도록 하였다.

모델링에서의 문제점도 존재하였다. body 를 undesired_contact 로 지정해놓은 코드가 효력을 발휘하려면 body 가 땅에 닿아야하지만 기존에 사용하던 헥사포드 로봇 모델은 body 의 두께보다 con 의 두께가 더 두꺼웠다.이는 body 보다 con 이 먼저 땅에 닿게 만들었고 con 이나 motor 를 통해 보행하는 학습 결과를 초래하였다. 이를 해결하기 위해 body 의 두께를 늘리게 되었다.

이번엔 보상 함수 구성에서의 문제이다. get_rewards 함수의 항목 중 joint_accel 이 불규칙하게 정규화가 되는 모습을 보여 삭제하였다. 또한 air_time 항목이 존재할 때, 그 보상을 최대화하기 위해 다리를 들어 움직이려는 경향을 보였고 이는 학습이 정상적으로 진행되지 않는 모습으로 나타났다. 그러나 반대로 air_time 항목을 삭제한 경우에는 다리의 체공 시간을 보장하는 것이 사라지다보니 걷는 모습에서 통통 튀는 어색한 현상을 보였다. 결론적으로 air_time 항목을 다시 넣게 되었고, 다리를 들어 움직이려는 경향을 보였던 것은 description 에서 lin_vel 을 우선으로 하라는 명시를 통해 해결하였다.

학습을 진행하면서 또 다른 모델에서의 문제점이 나타났다. 기존 헥사포드 모델에서 설정한 foot 으로 학습을 한 결과, 발 끝이 아닌 발의 최대한 넓은 면적으로 접촉을 유도하여 안정성을 확보하려는 경향을 보였다. 이는 실제 보행과는 다른 양상을 띄는 것이므로 foot 의 끝 부분만 toe 로 세분화하여 toe 로만 접촉할 수 있도록 수정하여 보행 동작을 보다 사실적으로 하도록 유도하였다.

이후 다시 학습 과정을 관찰하던 중 yaw 방향 각속도를 랜덤하게 목표 각속도로 주고 있었다는 것을 발견하였다. 그 결과 로봇이 이동을 하지 않고 빙글 도는 문제점이 발생하였다. 헥사포드 로봇은 구조상 뒤나 옆으로 이동할 때 회전이 필요 없기 때문에 목표 yaw rate 를 0 으로 고정시켜 이러한 문제점을 해결하였다.

4. 결과 및 한계

4.1 실험 결과

4.1.1 회차 간 비교

EUREKA 의 보상 평가, 수정 시스템이 헥사포드의 제대로 작동하였는지 알아보기 위해 첫 번째와 다섯 번째 회차를 비교하고자 한다. 한 번의 회차에는 세 개의 샘플이 사용되었으며 각각의 샘플로 2000 번의 강화학습을 진행했다. 그 중 다음 보상을 생성하는 프롬프트 입력값으로 이용된 샘플을 평가 기준으로 선정하였다. 전진속도를 최대화시키라는 명령을 task description 으로 제공했기 때문에 속도는 로봇의 전방인 x 축 방향 속도를 기준으로 측정하였다. 에이전트의 생성부터 소멸까지 최대 20 초간 헥사포드의 평균 속도를 기준으로 속도를 측정하였다.

실험 결과 첫 번째 회차에서 생성된 보상함수로 학습된 헥사포드 로봇의 x 축 속도는 -0.1~0.05m/s 사이를 오갔다. 이는 시뮬레이션을 통해 육안으로 확인했을 때 바닥에 달라붙어 거의 움직임이 없는 모습으로 나타났다. 반면 네 번의 수정을 추가적으로 거친 보상함수로 학습된 로봇의 경우 평균 x 축 속도가 초기 500 번의 학습 이내에 0.6m/s 까지 상승하였으며, 이후의 학습에서 최대 0.78m/s 까지 상승하였다. 시뮬레이션을 통해 육안으로 확인한 결과도 보행이라고 부를수 있는 깔끔한 이동을 보였다.

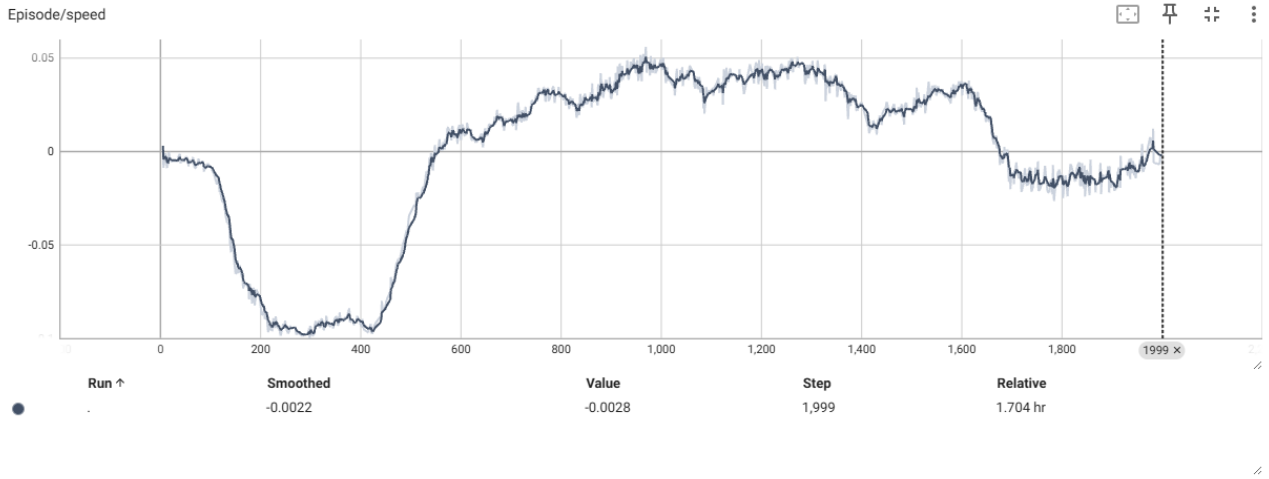

Fig. 3 Mean speeds of first iteration. The values on the x axis represent episodes of reinforcement learning.

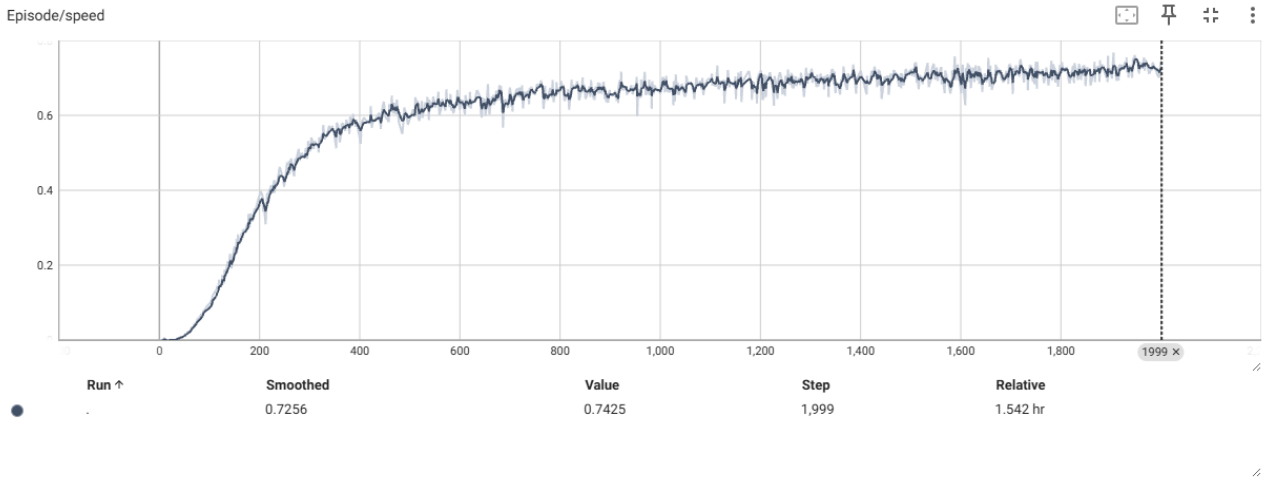

Fig. 4 Mean speeds of fifth iteration. The values on the x axis represent episodes of reinforcement learning.

그래프를 통해 확인할 경우 이러한 격차는 더 명확하게 드러난다. 첫 번째 생성된 보상함수를 통해 학습한 결과는 초반 학습 구간에서 음의 x 축 방향, 로봇 기준 뒤쪽으로 이동하는 경향을 보인다. 해당 에이전트는 결국 보상을 최대화시키는 방향으로 안정화시키지 못하고 무의미한 탐색만을 반복하다 종료되었다. 반면 다섯 번째 보상함수는 일정 구간까지 빠르게 안정화 된 후에 해당 지점에서 조금씩 탐색을 반복하며 전진 성능을 점차 개선해나가는 모습을 보였다.

첫 번째 회차 외에 이전 2~4 회차들과 비교했을 경우에도 회차를 반복할수록 안정화까지 걸리는 에피소드가 더 적었으며, 최종적인 x 축 방향 속도가 점점 높아지는 것을 확인할 수 있었다. 이런 데이터의 경향은 EUREKA 가 피드백을 통해 보상함수를 성공적으로 개선한다는 것을 나타낸다. 또한, 다양한 환경에서 속력이 크게 차이나지 않는 것을 통해 개선된 보상함수가 다양한 험지를 효과적으로 주파할 수 있음이 나타났다.

4.1.2 유효성

앞서 EUREKA 가 보상함수를 성공적으로 개선한다는 것을 확인하였으니 이번에는 그렇게 개선된 보상함수가 인간 설계자가 설계한 보상 함수와 비교하여 어느 정도의 성능을 가지는지 알아보고자 한다. 아쉽게도 IsaacLab 은 헥사포드에 대한 기본적인 예시 학습 환경을 제공하지 않으며, IsaacLab 을 적용하는 헥사포드의 학습 파일을 찾을 수 없었기에 우리는 학습 환경을 직접 작성하였다. 그렇기에 보상 함수만을 비교할 수 있는 명확한 기준이 존재하지 않는다. 따라서 본 연구에서는 앞서 살펴본 실험 결과와 다른 연구에서 제공하는 데이터를 이용한 정성적 분석을 통해 유효성을 살펴보고자 한다.

비교에 앞서 한가지 짚고 넘어가야 할 점이 있다. 로봇의 크기는 로봇의 보행 속도에 영향을 미치는 중요한 요소다. 일반적으로 로봇이 클수록 한 번의 보행으로 이동할 수 있는 거리 또한 길어진다. 따라서 보행 알고리즘의 성능을 비교하기 위해서는 몸체 길이와 이동속도의 비율로 정규화 된 수치를 성능을 확인하기 위한 지표로 이용하는 것이 타당하다. 본 연구에서 이용한 헥사포드 로봇의 바디 전후 길이는 18.8cm 이므로 로봇의 최종 전진 속도는 바디 기준 약 4.15BL/s(body lengths per second)가 된다.

주행속도에 초점을 맞춘 또 다른 연구에서는 고전적 알고리즘으로 우선적으로 학습시킨 신경망에 강화학습을 적용한 결과 헥사포드가 최대 2m/s 를 보이는 것을 확인할 수 있었다. 연구 영상에서 확인할 수 있는 해당 로봇의 몸체 길이는 1m 이며 몸체 길이에 상대적인 속도는 2BL/s 가 된다. 이는 다른 알고리즘을 적용한 동급의 로봇에 비해 유의미하게 빠른 주행 성능이라고 해당 논문에서 언급된다. 비록 로봇의 동체 속도와 무게가 로봇의 크기에 비례한 속도에 영향을 미치지만, 이는 작은 로봇이 가벼운 몸체와 모터의 파워를 이용하여 스스로의 몸을 앞으로 발사하거나, 몸을 공중에 띄워 이동 속력을 최대화 시키기 때문이다. 따라서 로봇이 보행을 통해 전진했다는 점을 미루어 보았을 때 5 배 작은 헥사포드가 4.15BL/s 로 이동하는 것은 괜찮은 수준의 보상 함수 생성을 달성했다 판단된다.

4.2 한계

본 연구는 EUREKA 를 기반으로 하기 때문에 EUREKA 가 가지는 문제점을 그대로 가진다. 우선 EUREKA 는 LLM 이 가지는 문제점을 해결하지 못하는데, 프롬프트 텍스트가 길어질 경우 요구를 제대로 이행하지 못하는 현상이 발생할 수 있으며, 사실이 아닌 정보를 사실인 것 처럼 생성하는 환각(hallucination) 문제 또한 존재한다. 실제로 실험 도중 정해진 코드 작성 형식에서 벗어나는 답변을 생성하여 샘플 중 일부가 학습이 진행되지 않는 문제점이 발견되었다.

EUREKA 는 시뮬레이션상에서 수많은 로봇들을 동시에 학습시키기 때문에 고성능의 GPU 와 시뮬레이션에 의존적이라는 단점이 있다. 시뮬레이션이 현실의 모든 요소를 정확하게 반영할 수 없기 때문에 이러한 특성은 EUREKA 를 이용하여 학습시킨 신경망을 현실의 로봇에 연결하였을 때의 성능을 평가하는 것을 어렵게 만든다. 본 연구에서는 각 환경마다 다양한 물리적 변수를 일정 범위 이내에서 무작위로 결정함으로써 그런 제한점을 최대한 줄이고자 하였다.

주행 성능을 평가하는 과정에서도 동일한 환경에서 인간 전문가가 설계한 보상 함수, 혹은 고전적 알고리즘을 이용하는 것이 아닌 다른 연구의 주행 성능 및 평가를 이용하여 정성적으로 평가하였기 때문에 유효성을 명확하게 보이지 못한다는 한계가 존재한다. 다만 이는 본 연구팀이 보상 함수 설계의 전문가가 아니며, 실험에 이용된 수준의 험지에 적용할 수 있는 고전적 알고리즘을 찾을 수 없기 때문에 발생한 어쩔 수 없는 선택이었다. 따라서 본 연구가 완성되기 위해서는 보상함수 설계 전문가의 추가적인 검증을 필요로 한다.

후 기

본 연구는 EUREKA 가 헥사포드의 보행을 강화시키는 데 필요한 보상함수를 효과적으로 개선할 수 있음을 보였으며, 다른 주행 연구와 비교하였을 때 괜찮은 주행 성능을 확인함으로써 헥사포드의 험지 보행을 학습시키는 데 EUREKA 가 유효한 시스템임을 입증하였다. 이는 추후 진행되는 헥사포드의 험지 보행 연구에서 EUREKA 가 보상함수의 최적화를 위해 고려할 수 있는 옵션이라는 것을 의미한다.

또한 험지를 랜덤하게 생성하여 헥사포드가 현재 보행하는 지형이나 환경의 정보를 제공받지 못한 채로 제대로 보행할 수 있다는 것을 보였다. 이는 선행 연구에서 검증하지 못한 부분 관측 마르코프 결정 과정(POMDP) 환경에서의 EUREKA 의 유효성을 일부 입증하며, 향후 다양한 POMDP 문제로 EUREKA 의 적용 범위를 확장할 수 있다는 것을 시사한다.

참고문헌
(References)

(1) Ding, X., Wang, Z., Rovetta, A., & Zhu, J. M., 2010, “Locomotion analysis of hexapod robot,” *Climbing and walking robots*, pp. 291-310.
(2) Anandkumar, A., Bastani, O., Fan, L., Huang, D.-A., Jayaraman, D., Liang, W., Ma, Y. J., Wang, G., and Zhu, Y., 2023, “Eureka: Human-Level Reward Design Via Coding Large Language Models”, *ICLR 2024 Proceedings*
(3) Huang, S., Xiao, Z., Zheng, M., & Shi, W., 2025, “Hierarchical reinforcement learning for enhancing stability and adaptability of hexapod robots in complex terrains,” *Biomimetic Intelligence and Robotics*, 100231.
(4) Li, D., Wei, W., & Qiu, Z., 2023, “Combined Reinforcement Learning and CPG Algorithm to Generate Terrain-Adaptive Gait of Hexapod Robots,” *Actuators*, Vol.12 (4), p. 157.
(5) Deng, Z., Ding, L., Gao, H., Liu, T., Pajarinen, J., Wang, H., Xu, P., Yang, H., & Zhang, Z., 2025, “Imitation-Enhanced Reinforcement Learning With Privileged Smooth Transition for Hexapod Locomotion,” *IEEE Robotics and Automation Letters*, Vol.10 (1), pp.350-357
(6) Birkmeyer ,P. & Fearing, R. S., 2009, "DASH: A resilient high-speed 15g hexapedal robot," *2009 IEEE/RSJ*

International Conference on Intelligent Robots and Systems, pp. 418-419